

Clasificación de nubes de puntos a gran escala mediante procesamiento paralelo acelerado por GPU

Nick Thomas¹, Mark Monro Searle², Mateo Ubeda³

Facultad de Ingeniería, Universidad Nacional de Colombia

¹nthomas@unal.edu.co

²msearle@unal.edu.co

³mubeda@unal.edu.co

Abstract— LiDAR technology has emerged as a fundamental tool for the acquisition of detailed 3D representations of the Earth's surface. In urban environments, airborne LiDAR scanning (ALS) produces large, complex point clouds that contain rich spatial information but also present significant computational and analytical challenges. This preliminary study presents the first stage of a project aimed at developing a GPU-accelerated algorithm for the classification of ground points in urban LiDAR point clouds. The input dataset, provided by the Empresa de Acueducto y Alcantarillado de Bogotá (EAAB-ESP), covers a portion of the city of Bogotá and contains over 48 million points. After describing the nature of LiDAR point cloud data, we detail the preprocessing pipeline—including outlier removal, last-return filtering, and temporal ordering by GPS time—as well as the implementation of the ground classification algorithm using CUDA and Python. This document serves as a foundation for further development of the classification method and will support the future extraction of higher-level patterns in urban point clouds.

Keywords— LiDAR, point cloud, airborne laser scanning (ALS), ground classification, GPU acceleration, CUDA, Numba, geospatial data, digital terrain model (DTM), urban remote sensing, large-scale 3D data.

I. INTRODUCTION

LiDAR es un método de teledetección que ha cobrado una gran relevancia en las últimas décadas [1]. Los escáneres LiDAR pueden montarse en automóviles, trípodes, drones, aviones y satélites. Estos dispositivos emiten haces de luz de diferentes longitudes de onda (normalmente en el infrarrojo cercano) que se reflejan en los objetos y son detectados nuevamente por el escáner. Al calcular el tiempo que tarda el haz de luz en viajar y al medir la posición y orientación exactas del escáner en el momento de la emisión, es posible determinar con precisión la ubicación del objeto que produjo el reflejo. El escáner distribuye estos haces de luz mediante distintos mecanismos y emite miles de pulsos por segundo, lo que permite generar grandes conjuntos de datos tridimensionales, o nubes de puntos, en períodos de tiempo relativamente cortos.

En el caso de un escáner montado en un avión —lo que se conoce como escaneo láser aerotransportado (ALS, por sus siglas en inglés)—, es posible crear conjuntos de datos a gran escala que abarcan varios kilómetros cuadrados e incluso

ciudades enteras o elementos del paisaje [2]. Los escáneres LiDAR registran la posición de cada punto retornado, así como otros atributos de la señal de retorno, como la intensidad y la reflectancia.

La mejora de los dispositivos de escaneo y, especialmente, de las capacidades para procesar los datos generados ha llevado a un aumento significativo en la relevancia de la investigación y el análisis basados en LiDAR en las últimas décadas. Actualmente, los datos LiDAR se utilizan en diversas aplicaciones como la cartografía, la planificación urbana y la investigación climática [3]. El principal desafío en el uso de estos datos radica en el tamaño masivo de los conjuntos (millones o miles de millones de puntos, desde gigabytes hasta terabytes de información), así como en la baja densidad informativa de las nubes de puntos. Por ello, se requieren métodos de análisis de grandes volúmenes de datos que permitan procesar eficientemente estos conjuntos y extraer información relevante para los usuarios interesados [4].

En el contexto de las nubes de puntos LiDAR de entornos urbanos, un reto específico es la clasificación o etiquetado de los puntos según los objetos a los que pertenecen, tales como el suelo, edificaciones o vegetación. Esta clasificación es fundamental para una amplia variedad de aplicaciones como el análisis del uso del suelo, el apoyo a la conducción autónoma, la monitorización de infraestructuras, la gestión de desastres y la evaluación de riesgos, así como para una gestión eficiente de los datos [5]. Además, constituye un paso esencial para la generación de Modelos Digitales del Terreno (DTM), los cuales representan con precisión la superficie del suelo libre de objetos como edificios y vegetación, y son ampliamente utilizados en aplicaciones topográficas, hidrológicas, de planificación urbana y análisis ambiental [6].

En nuestro trabajo, nos proponemos desarrollar un algoritmo novedoso capaz de clasificar puntos del terreno a partir de nubes de puntos urbanas a gran escala, utilizando procesamiento paralelo acelerado por GPU. En este artículo preliminar, presentamos nuestro conjunto de datos, así como los pasos de preprocesamiento que emplearemos antes del análisis. Además, describimos el funcionamiento general del

algoritmo propuesto y exponemos los desafíos que anticipamos enfrentar.

II. NUBES DE PUNTOS LiDAR

La naturaleza de las adquisiciones de datos LiDAR otorga a las nubes de puntos obtenidas mediante esta tecnología una serie de atributos clave que serán aprovechados en el presente análisis [7][8].

El primero de estos es el *GPS time*. Durante una adquisición LiDAR, el escáner registra una marca temporal (timestamp) para la recolección de cada punto individual en la nube. Esto permite ordenar los puntos según el tiempo de adquisición y, de forma indirecta, proporciona una indicación preliminar de su distribución espacial. Los puntos registrados en momentos similares tienden a encontrarse también próximos entre sí en el espacio. La naturaleza de esta relación espacial depende, en primer lugar, de la forma de los objetos escaneados. Sin embargo, el patrón de escaneo también influye en dicha relación. Los escáneres ALS suelen utilizar un mecanismo mecánico para distribuir el haz láser en dirección perpendicular al sentido de vuelo. Los distintos patrones de escaneo que emplean actualmente los escáneres láser comerciales convencionales se presentan en la Figura 1.




Fig 1.: Patrones de escaneo de ALS [7]

En segundo lugar, el haz láser de una adquisición LiDAR posee un cierto tamaño al momento de intersectar con un objeto en el suelo. Durante la adquisición, la anchura del haz puede reflejarse en varios objetos diferentes, lo que da lugar a múltiples picos en la señal de retorno, conocidos como ecos. Esto permite que el escáner detecte varios objetos dentro de un mismo pulso, los cuales se registran como múltiples retornos del mismo pulso. El escáner almacena esta información como un atributo de cada punto en la nube, donde el *number of returns* (número de retornos) indica cuántos ecos se obtuvieron a partir del pulso correspondiente, y el *return number* (número de retorno) indica el índice específico del eco dentro de su respectivo haz. Así, el punto con *número de retorno* = 1 representa el primer eco del haz, mientras que en un pulso con cinco retornos, el *número de retorno* = 5 indica el último eco registrado por ese haz. Por lo tanto, los puntos con el número de retorno más alto dentro de cada haz

representan el objeto más bajo registrado por dicho haz (Figura 2).

Esto resulta especialmente relevante en el caso de pulsos que penetran vegetación, donde se registran múltiples ecos en el follaje y el último eco suele corresponder al suelo debajo de la vegetación, siempre que el haz penetre completamente hasta el terreno. En zonas urbanas, este fenómeno también puede ocurrir cuando un haz intersecta con esquinas de edificaciones, vehículos, postes de alumbrado u otros objetos que se encuentren por encima del nivel del suelo.




Figura 2: Visualización de múltiples picos en la señal de retorno (<https://pro.arcgis.com/en/pro-app/latest/help/data/las-dataset/what-is-lidar.html>)

III. DATOS

El conjunto de datos de prueba para nuestro análisis fue amablemente proporcionado por la Empresa de Acueducto y Alcantarillado de Bogotá (EAAB-ESP), tras la presentación de un derecho de petición conforme a lo establecido en el artículo 23 de la Constitución Política de Colombia y la Ley 1755 de 2015. Este conjunto de datos forma parte de una campaña de levantamiento LiDAR realizada en toda la ciudad de Bogotá, encargada por la EAAB-ESP y adquirida en el año 2021. El subconjunto utilizado corresponde a la Localidad 13 - Teusaquillo y abarca la totalidad del campus de la Sede Bogotá de la Universidad Nacional de Colombia. La Figura 2 muestra la extensión de nuestro conjunto de datos.

La nube de puntos cubre un área de aproximadamente 1,65 km² y contiene 48.165.913 puntos, lo que resulta en una densidad de aproximadamente 29 puntos por metro cuadrado. Los atributos de cada punto son: *intensity*, *return number*, *number of returns*, *scan direction flag*, *edge of flight line flag*, *classification*, *scan angle*, *point source id* y *GPS time*. El atributo *classification* contiene 5 clases diferentes, pero parece bastante rudimentaria y probablemente fue realizada por un algoritmo automatizado y mal configurado por la EAAB-ESP.

La nube de puntos se guarda en un archivo LAS, que es un formato binario estandarizado para el intercambio de datos LiDAR, desarrollado por la American Society for Photogrammetry and Remote Sensing (ASPRS). Es ampliamente utilizado en aplicaciones geoespaciales debido a su eficiencia e interoperabilidad. Las explicaciones de los atributos almacenados se pueden encontrar en el sitio web de

la ASPRS. Los atributos relevantes para este análisis se explican en la sección sobre teoría del LiDAR [8].




Fig 2.: Extensión del conjunto de datos LiDAR

IV. PREPROCECAMIENTO

A. Filtración Outliers

Las nubes de puntos LiDAR ALS sin procesar pueden contener imperfecciones que deben abordarse antes del análisis. Especialmente en adquisiciones urbanas, las reflexiones de los pulsos láser pueden provocar un retraso en la señal de retorno y generar valores atípicos por debajo de la escena capturada. Las nubes y la humedad en el aire también pueden generar valores atípicos muy por encima de la escena. Por lo tanto, es necesario realizar primero una limpieza y eliminación de estos valores atípicos.

Para eliminar estos valores atípicos de la nube de puntos, se aplica un método de filtrado estadístico basado en la estimación de densidad local mediante vecindarios. La idea central consiste en evaluar la densidad espacial local de cada punto en función de la distancia a sus k vecinos más cercanos. Los puntos que se encuentran en regiones con densidad inusualmente baja se consideran atípicos y se excluyen del conjunto de datos.

El algoritmo implementado construye primero un índice espacial utilizando *cKDTree*, lo que permite realizar consultas eficientes de los vecinos más cercanos. Para cada punto en la nube, se calcula la distancia a su k -ésimo vecino más cercano. Suponiendo un vecindario esférico, se estima el volumen alrededor de cada punto utilizando la fórmula del volumen de una esfera. Luego, la densidad local del punto se calcula como la razón entre el número de vecinos y el volumen estimado. Esto da como resultado un valor de densidad para cada punto, que refleja cuán agrupado o aislado está en el espacio tridimensional.

Una vez que se han calculado los valores de densidad para todos los puntos, se aplica un umbral basado en percentiles:

los puntos con densidades por debajo de un determinado percentil (en este caso, el percentil 1) se consideran valores atípicos estadísticos y se eliminan del conjunto. Este enfoque permite filtrar eficazmente regiones con densidad extremadamente baja, que probablemente se deben a ruido del sensor, reflexiones o interferencias atmosféricas.

B. Last Return Filtración

Dado que el objetivo de nuestro análisis es extraer los puntos del terreno a partir de los datos, es posible filtrar aún más la nube de puntos para incluir únicamente los puntos relevantes. En los pulsos con múltiples retornos, solo el último retorno puede haberse reflejado en el suelo. Por lo tanto, solo se conservan los puntos donde el *return number* es igual al *number of returns*. Esta operación reduce el tamaño de la nube de puntos de XX a YY puntos.

C. Ordenar por tiempo GPS

Dado que el algoritmo se basa en la naturaleza de los valores de *GPS time* cercanos para inferir una relación espacial próxima entre los puntos, es necesario que la nube de puntos esté ordenada por *GPS time*. Esto se logra utilizando PDAL, una biblioteca en C++ diseñada para la traducción y manipulación de datos de nubes de puntos [9].

V. METODOS

El algoritmo final recibe una nube de puntos previamente depurada, con los valores atípicos eliminados y compuesta únicamente por los últimos retornos, la cual está ordenada según sus valores de *GPS time*. La nube de puntos se carga inicialmente utilizando la biblioteca *laspy*, que permite el acceso directo al formato de archivo LAS. Los atributos relevantes—las coordenadas x , y , z , así como *return number* y *number of returns* se extraen y se estructuran en un arreglo de NumPy. Los puntos identificados como últimos retornos se pasan posteriormente a un kernel CUDA para su clasificación.

El núcleo del algoritmo está implementado utilizando el compilador CUDA JIT de Numba, que permite ejecutar kernels personalizados en GPU directamente desde Python [10]. Para paralelizar el proceso, la nube de puntos filtrada (solo con los últimos retornos) se divide en segmentos espaciales de tamaño fijo. A cada hilo de ejecución en CUDA se le asigna uno de estos segmentos, que procesa de forma independiente. Dentro de cada segmento, el algoritmo identifica primero el punto con menor elevación, que se considera un candidato probable a representar el terreno. Luego, evalúa los demás puntos del segmento comparando sus diferencias de elevación con respecto a este punto más bajo.

Se aplica un criterio simple basado en la pendiente máxima permitida para determinar la probabilidad de que un punto pertenezca al terreno: la diferencia de elevación (*zdiff*) entre cada punto y el punto más bajo se compara con una diferencia máxima aceptable, calculada como el producto de la distancia horizontal y la tangente del ángulo de pendiente máximo definido por el usuario. Si la diferencia real de elevación es menor que este umbral, el punto se clasifica como terreno.

Dado que los puntos son recolectados en líneas por el escáner, cada segmento representa una línea de puntos a través de la escena. Por lo tanto, el parámetro que define el número de segmentos debe elegirse de manera que cada uno cubra una extensión suficientemente grande como para incluir al menos un punto del terreno. De lo contrario, es teóricamente posible que una línea se ubique por completo sobre una estructura, como un edificio, y que el algoritmo clasifique erróneamente algunos de esos puntos como pertenecientes al terreno.

El resultado final es una máscara binaria para la nube de puntos original, en la que cada punto se etiqueta como perteneciente o no al terreno, según el filtrado. Este método acelerado por GPU ofrece mejoras de rendimiento sustanciales en comparación con enfoques tradicionales basados en CPU, y es capaz de procesar decenas de millones de puntos en cuestión de segundos, dependiendo del tamaño de segmento seleccionado y del hardware disponible.

VI. HARDWARE

El algoritmo se ejecuta y prueba en una GPU NVIDIA Quadro P4000 con 8 GB de memoria dedicada, instalada en una estación de trabajo ubicada en la Facultad de Ciencias Geológicas de la Universidad de Potsdam [11]. El acceso a la GPU se realiza de forma remota mediante una conexión SSH, lo que permite el desarrollo y la evaluación del algoritmo sin necesidad de acceso físico directo al equipo.

VII. CONCLUSIÓN

En este trabajo preliminar se ha desarrollado una base metodológica sólida para el procesamiento y análisis de grandes nubes de puntos LiDAR en entornos urbanos. Se presentó un algoritmo acelerado por GPU que permite identificar puntos del terreno a partir de retornos láser, aprovechando propiedades clave de los datos como el número de retorno, el tiempo GPS y la distribución espacial de los pulsos. Además, se describió el proceso de limpieza y prefiltrado necesario para preparar el conjunto de datos, así como los desafíos que plantea su gran volumen.

Sin embargo, los requisitos específicos establecidos para esta etapa del proyecto no pudieron ser cumplidos en su totalidad. El objetivo de aplicar mínimo dos algoritmos de asociación y tres algoritmos de agrupamiento, así como la extracción de reglas y la comparación de modelos, no pudo realizarse debido a la naturaleza particular de los datos. Las nubes de puntos LiDAR, al ser conjuntos masivos de datos espaciales tridimensionales con baja densidad semántica por punto, no se ajustan fácilmente a las estructuras tabulares que normalmente se requieren para este tipo de algoritmos. Además, todo el enfoque de este proyecto está orientado justamente a convertir datos crudos en información

clasificable y estructurada, lo cual es un requisito previo para aplicar técnicas como asociación o agrupamiento con sentido.

REFERENCES

- [1] C. Wehr and A. Lohr, "Airborne laser scanning—an introduction and overview," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 54, no. 2–3, pp. 68–82, 1999.
- [2] E. Baltsavias, "Airborne laser scanning: basic relations and formulas," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 54, no. 2–3, pp. 199–214, 1999.
- [3] J. Shan and C. K. Toth, *Topographic Laser Ranging and Scanning: Principles and Processing*, 2nd ed. Boca Raton, FL, USA: CRC Press, 2018.
- [4] T. Hackel, J. D. Wegner, and K. Schindler, "Fast semantic segmentation of 3D point clouds with strongly varying density," *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. 3, no. 3, pp. 177–184, 2016.
- [5] J. Niemeyer, F. Rottensteiner, and U. Soergel, "Contextual classification of LIDAR data and building object information," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 87, pp. 152–165, 2014.
- [6] K. Kraus and N. Pfeifer, "Determination of terrain models in wooded areas with airborne laser scanner data," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 53, no. 4, pp. 193–203, 1998.
- [7] L. Winiwarter, A. M. Esmoris Pena, H. Weiser, K. Anders, J. Martínez Sánchez, M. Searle y B. Höfle, "Virtual laser scanning with HELIOS++: A novel take on ray tracing-based simulation of topographic full-waveform 3D laser scanning," *Remote Sensing of Environment*, vol. 269, art. no. 112772, 2022. doi: 10.1016/j.rse.2021.112772.
- [8] The American Society for Photogrammetry and Remote Sensing (ASPRS), *LAS Specification 1.4 – Revision 15*, Jul. 9, 2019. [Online]. Available: ASPRS website
- [9] PDAL Developers, "PDAL Point Data Abstraction Library," [Online]. Available: <https://pdal.io>. [Accessed: Jun. 19, 2025].
- [10] S. Lam, A. Pitrou, and S. Seibert, "Numba: A LLVM-based Python JIT compiler," in *Proceedings of the Second Workshop on the LLVM Compiler Infrastructure in HPC*, Austin, TX, USA, 2015, pp. 1–6.
- [11] NVIDIA Corporation, "NVIDIA Quadro P4000 Datasheet," [Online]. Available: <https://www.nvidia.com/en-us/design-visualization/quadro/> [Accessed: Jun. 19, 2025].